



魅力统计

Fascinating Statistics

第七章 常用监督学习模型与方法II

Chapter 7 Common Supervised Learning Models and
Methods II


第七章 常用监督学习模型与方法II

- 7.1 树木与森林
- 7.2 神经网络模型
 - 7.2.1 神经网络的发展史
 - 7.2.2 卷积神经网络
 - 7.2.3 循环神经网络
 - 7.2.4 注意力机制与Transformer




7.1 树木与森林

- 我们曾绘制鸢尾花的花瓣长度和宽度的散点图.
- 由此图不难构建一个简单的人类决策过程. 如:





- 这样的决策过程是一种If/ELSE判别式嵌套的树形结构, 这就是**决策树(decision tree)**.




7.1 树木与森林

- 基于树的方法是最常用的监督学习方法之一,可用于回归与分类任务(主要讨论分类任务)
 - Breiman等人于1984年提出的CART (classification and regression tree)算法使得基于树的方法开始流行起来.
 - 决策树的基本思想是通过一些IF/ELSE规则,递归地将特征空间划分为互不相交的区域,落入同一个区域的实例的Y较为相似.



7.1 树木与森林

- 决策树的结构如右图所示, 每个内部节点表示一个特征或属性, 每个叶节点代表一个类别.
- 决策树的学习过程: 通过训练数据来确定选择什么属性作为内部节点, 以及用所选属性的哪个值作为划分.
- 决策树的预测过程: 将测试实例从根节点开始, 沿着划分属性所构成的“判定测试序列”下行, 直到达到叶节点.
- 构建决策树的本质是**根据训练数据自主选择判别条件**.
- 一个自然的问题是如何判断所选判别条件是否是最优的?
- 下面介绍三个分类决策树常用的评价标准: **错分类误差**、**信息增益/信息增益比**、**基尼不纯度**.



7.1 树木与森林

例7.1

下表是一个由15个实例组成的贷款申请训练数据, 包含贷款申请人的4个特征: 年龄(青年/中年/老年), 是否有工作(是/否), 是否有房(是/否), 信贷情况(非常好/好/一般). 响应变量是是否同意贷款(是/否).


ID	年龄	有工作	有房	信贷情况	贷款	ID	年龄	有工作	有房	信贷情况	贷款
1	青年	否	否	一般	否	9	中年	否	是	非常好	是
2	青年	否	否	好	否	10	中年	否	是	非常好	是
3	青年	是	否	好	是	11	老年	否	是	非常好	是
4	青年	是	是	一般	是	12	老年	否	是	好	是
5	青年	否	否	一般	否	13	老年	是	否	好	是
6	中年	否	否	一般	否	14	老年	是	否	非常好	是
7	中年	否	否	好	否	15	老年	否	否	一般	否
8	中年	是	是	好	是						

希望基于此数据学习一个贷款申请的决策树, 用以对未来的贷款申请进行分类.



7.1 树木与森林

- 考虑选择用是否有工作或是否有房作为判别条件:



- 错分类误差 (misclassification error, ME) 就是分类错误的概率.

- 按照多数投票规则决定两个分支的类别, 并计算两个分支的错分类误差, 再依据两个分支的实例数求其错分类误差的加权平均, 得到此判别条件的错分类误差.



7.1 树木与森林

- 介绍信息增益(information gain)之前,需要了解一个信息论的概念—信息熵(entropy, 简称熵).
 - 熵是1854年由克劳修斯(Clausius)提出的一个用于度量体系混乱程度的单位.
 - 熵增原理: 在孤立系统中, 体系与环境没有能量交换, 体系总是自发地向混乱度增大的方向变化, 使整个系统的熵值增大.
 - 1948年, 香农(Shannon)将热力学的熵引入到信息论中, 表示对不确定性的度量.

信息熵

若离散型随机变量 Y 的概率分布为

$$P(Y = a_i) = p_i, i = 1, 2, \dots, K,$$

则 Y 的熵 $H(Y)$ 定义为

$$H(Y) = - \sum_{i=1}^K p_i \log_2(p_i).$$

- 例如考虑一枚正面概率为 p , 反面概率为 $1 - p$ 的硬币. 若 $p = 0$ 或 1 , 则抛硬币的结果是确定的, 熵为0.



7.1 树木与森林

■ 熵与信息论有什么关系呢?

- 日常中,大家常常会听到信息量大这个说法.越大概率的事件发生了所产生的信息量越小.
- 信息量度量的是一个具体事件发生所带来的信息的多少,而熵是在结果出来之前对可能产生的信息量的期望.

$$H(Y) = - \sum_{i=1}^K p_i \log_2(p_i)$$

信息量的期望

信息量

- 信息增益表示得知特征 X 的信息而使得 Y 的不确定性减少的程度,可简单表示为


$$g(Y; X) = H(Y) - H(Y|X).$$

- 应选择带来信息增益大的特征作为判别条件.



7.1 树木与森林

- 仍然考虑例7.1中选择用是否有工作或是否有房作为判别条件:



$$H(Y) = -\frac{9}{15} \log_2 \left(\frac{9}{15} \right) - \frac{6}{15} \log_2 \left(\frac{6}{15} \right) = 0.971.$$

$$H(Y|\text{有工作}) = 0,$$

$$H(Y|\text{无工作}) = -\frac{6}{10} \log_2 \left(\frac{6}{10} \right) - \frac{4}{10} \log_2 \left(\frac{4}{10} \right) = 0.971.$$

$$H(Y|\text{工作}) = \frac{5}{15} \times H(Y|\text{有工作}) + \frac{10}{15} \times H(Y|\text{无工作}) = 0.647.$$

$$g(Y; \text{工作}) = H(Y) - H(Y|\text{工作}) = 0.971 - 0.647 = 0.324.$$

- 同理可算得: $g(Y; \text{房产}) = H(Y) - H(Y|\text{房产}) = 0.971 - 0.551 = 0.420$. 
- 因此, 相对于是否有工作, 是否有房是更好的判别条件.



7.1 树木与森林

- 随机变量的熵有一个特点:
 - 当随机变量有 K 个取值时, 这 K 个取值是等概率时, 熵最大.
 - 且 K 越大时, 熵的最大值越大.
 - 因此, 特征的取值个数会在一定程度上影响信息增益, 如果以信息增益作为选择最优特征的标准, 则存在偏向于选择取值较多的特征的问题. 如何解决这个问题?
 - 一个自然的思路是对信息增益做标准化, 提出信息增益比.
- 信息增益比(information gain ratio)是信息增益 $g(Y; X)$ 与 X 的熵 $H(X)$ 的比值:

$$g_R(Y; X) = \frac{g(Y; X)}{H(X)}.$$



7.1 树木与森林

- 最后介绍基尼不纯度(Gini impurity):
 - 我们常常听说的基尼系数(Gini coefficient)是用于衡量收入分配公平程度的指标.
 - 这里介绍的基尼不纯度有时也被称为基尼指数(Gini index), 是与基尼系数无关的指标.

基尼不纯度

若离散型随机变量 Y 的概率分布为

$$P(Y = a_i) = p_i, i = 1, 2, \dots, K,$$

则 Y 的基尼不纯度定义为


$$\text{Gini}(Y) = \sum_{i=1}^K p_i(1 - p_i) = 1 - \sum_{i=1}^K p_i^2.$$

- 基尼不纯度的理解:
 - 基尼不纯度衡量的的是一个随机选中的样本被错误分类(按照各类别概率随机分类)的概率, 这个概率越小表示总体中的类别的纯度越高.
 - 另外, 基尼不纯度可以视为熵的近似值, 因为由一阶泰勒展开有 $\log(x) \approx x - 1$.



7.1 树木与森林

- 与信息增量类似, 基于基尼不纯度进行特征选择时, 应选择基尼不纯度降低最多的特征.
- 再次考虑例7.1中选择用是否有工作或是否有房作为判别条件:



$$\text{Gini}(Y) = 1 - \left(\frac{9}{15}\right)^2 - \left(\frac{6}{15}\right)^2 = 0.48.$$

$$\text{Gini}(Y|\text{有工作}) = 0,$$

$$\text{Gini}(Y|\text{无工作}) = 1 - \left(\frac{6}{10}\right)^2 - \left(\frac{4}{10}\right)^2 = 0.48.$$

$$\begin{aligned}\text{Gini}(Y|\text{工作}) &= \frac{5}{15} \times \text{Gini}(Y|\text{有工作}) + \frac{10}{15} \times \text{Gini}(Y|\text{无工作}) \\ &= 0.32.\end{aligned}$$


$$\text{Gini}(Y; \text{工作}) = \text{Gini}(Y) - \text{Gini}(Y|\text{工作}) = 0.48 - 0.32 = 0.16.$$

$$\begin{aligned}\text{Gini}(Y; \text{房产}) &= \text{Gini}(Y) - \text{Gini}(Y|\text{房产}) \\ &= 0.48 - 0.267 = 0.213.\end{aligned}$$



7.1 树木与森林

- 只有两个类别时, 三种评价标准的关系如下: (其中熵缩放至通过点(0.5, 0.5))



- 由此可见, 信息熵和基尼不纯度是可微的, 更适用于数值优化.



7.1 树木与森林

- 这里简单介绍关于决策树的一些其他细节.
- 关于不同的决策树生成算法:
 - 有许多不同的决策树生成算法, 它们构建树时使用的树形结构、评价标准可能有所不同.
 - 如前面提到过的CART算法, 它使用的是二叉树, 用于分类任务时的评价标准是基尼不纯度.
 - 当类别型特征有多个值时 (例7.1中的年龄、信贷情况), 可以构建多叉树, 每个值各对应一个分支. 也可以构建二叉树, 以某个值的“是”或“否”对应两个分支, 此时不仅是单纯地选择最优特征, 而是选择最优特征-切分点组合.
- 关于决策树的剪枝(pruning):
 - 在决策树的生成中, 我们递归地产生分支, 直到不能继续下去.
 - 这样的树往往对训练数据的分类很准确, 对测试数据的分类效果不佳, 即6.6节中提到的过拟合现象.
 - 解决问题的办法是考虑决策树的复杂度, 对已生成的决策树进行简化, 这个过程称为剪枝.
 - 具体地, 从已生成的树上裁剪一些子树或叶节点, 将其父节点作为叶节点从而简化树模型.



7.1 树木与森林

- 决策树有许多优点:
 - 易于理解与解释, 是对人类进行决策过程的模仿, 可直接对决策过程进行可视化;
 - 数据预处理要求较低, 能自动进行特征选择, 能自动捕捉到特征的非线性影响和特征间的交互作用;
- 但决策树也有一些缺陷, 使得其在实际应用中的效果不佳.
 - 最主要的缺陷是决策树的**方差较大**, 即数据的微小变动可能导致生成的树完全不同.
 - 方差较大的主要原因是决策树的构建过程天然具有层次性, 因此顶层的误差会一直向下传递.
- 机器学习中一个常用于解决高方差问题的技术—**集成学习(ensemble learning)**.
 - 集成学习的基本思路是, 不试图构建单个完美模型, 而是组合多个简单模型(称为**弱学习器, weak learner**)成为一个强模型.
 - 思想内核类似“三个臭皮匠, 顶个诸葛亮”.
 - 你认为多个弱学习器需要满足什么要求呢?



7.1 树木与森林

■ 集成学习:


- 首先, 弱学习器不能太“弱”, 例如在二分类问题中, 弱学习器的准确率不能低于0.5.
- 其次, 弱学习器之间要有“多样性”, 即要存在差异.
- 因此, 在集成学习中, 如何构建多个弱学习器是最主要的问题.
- 装袋(Bagging)和**提升(Boosting)**是常用的产生多个弱学习器的方法.

■ 简单介绍Bagging的基本思想:

- 通过有放回随机抽样产生训练数据的多个“副本”.
- 对每个副本训练一个基础模型.
- 最终模型是各个模型的加权平均或多数投票.

■ 随机森林(random forest)是Bagging的最常见示例, 其每个基础模型都是一棵决策树.

- 除了训练数据随机抽样外, 每棵树都会基于**特征的随机子集**构建, 以使得每棵树更加不同.




第七章 常用监督学习模型与方法II

- 7.1 树木与森林
- 7.2 神经网络模型
 - 7.2.1 神经网络的发展史
 - 7.2.2 卷积神经网络
 - 7.2.3 循环神经网络
 - 7.2.4 注意力机制与Transformer




7.2.1 神经网络的发展史

- 追根溯源, 神经网络诞生于人类对于人脑和智能的追问.
 - 1906年第六届诺贝尔生理学或医学奖, 颁给了意大利生理学家卡米洛·高尔基(Camillo Golgi)和西班牙组织学家圣地亚哥·拉蒙·卡哈尔(Santiago Ramón y Cajal), 以表彰他们在神经科学方面作出的杰出贡献.



7.2.1 神经网络的发展史

- 1873年,高尔基在实验室给大脑组织染色时,不小心将硝酸银泼到已用重铬酸钾固定的组织上,结果在显微镜下进行观察时,惊讶地发现两者反应后产生的沉淀将一部分神经细胞染成了黑色.
- 这一染色技术后来被称为**高尔基染色法(Golgi staining)**,经染色处理的神经组织中的神经细胞和神经胶质细胞变成棕黑色,为神经科学的研究提供了最基础的组织学方法,并沿用至今.
- 1887年,卡哈尔改进了高尔基染色法,他建立的**还原硝酸银染色法**能显示最细的神经末端,染色的细胞和组织达到前所未有的清晰度,这让他能观察到神经细胞的精细结构.
- 虽然他们的研究方法同源,但他们对神经系统的结构却持有截然不同的观点.
- 高尔基支持“**网状理论(reticular theory)**”,认为神经系统是一个整体、连续的神经纤维网络,类似循环系统的动脉和静脉,而不是由离散的细胞单元组合而成.
- 卡哈尔则认为每个神经细胞都是一个独立的生理功能单位,它们是神经系统的基本单位,它们之间是不连续的,但神经信号可以跨过不相连的组织结构来进行传递.





7.2.1 神经网络的发展史

- 后有学者基于卡哈尔的研究将神经细胞命名为**神经元(neuron)**, 提出“**神经元学说**”(the neuron doctrine).
- 两者的争论一直到20世纪50年代电子显微镜的出现才画上句号, 在电子显微镜下清楚地看到了神经元与神经元之间的**突触结构**.
- 事实证明, 网状理论是错误的, 神经元学说才是正确的.
- 卡哈尔对于大脑的微观结构研究是开创性的, 被许多人认为是**现代神经科学之父**.



7.2.1 神经网络的发展史

- 1943年, 神经科学家Warren McCulloch和逻辑学家Walter Pitts发表论文《A Logical Calculus of the Ideas Immanent in Nervous Activity》, 首次提出神经元的M-P模型.
- 该模型借鉴了生物神经元的结构, 是人类第一个生物神经元数学模型. 此模型虽然简单, 但建立了神经网络大厦的地基.



g 是聚合操作,
即加权求和

h 是激活操作, 如聚合值
达到阈值才输出信号



7.2.1 神经网络的发展史

- M-P模型中聚合操作的权重值是预先设置的,没有学习的概念.
- 1949年,加拿大心理学家Donald Hebb在专著《The Organization of Behavior》提出了著名的赫布理论(Hebbian theory),解释了在学习的过程中脑中神经元所发生的变化.
- 赫布理论描述了突触可塑性的基本原理,即突触前神经元向突触后神经元的持续重复的刺激,可以导致突触传递效能的增加.
- 于是科学家们开始考虑用调整权值的方法让机器学习,这为后面的学习算法奠定了基础.但由于当时的计算机能力有限,直到接近10年后,第一个真正意义的人工神经网络才诞生.
- 1957年,美国心理学家Frank Rosenblatt发明了感知机(perceptron),它可被视为一种最简单的神经网络,可用于二分类任务.
- 感知机是人工神经网络的第一个实际应用,标志着神经网络进入了新的发展阶段.
- 1969年,美国认知科学家Marvin Minsky和数学家Seymour Papert发表《Perceptrons: an introduction to computational geometry》一书,从数学的角度证明了单层感知机仅具有有限功能,甚至在面对简单的“异或”逻辑时也显得无能为力.




7.2.1 神经网络的发展史

- Minsky认为, 如果将计算层增加到两层, 计算量则过大, 且没有有效的学习算法, 所以他认为研究更深层的网络是没有价值的.
- 由于Minsky的巨大影响力以及书中呈现的悲观态度, 让很多学者和实验室纷纷放弃了神经网络的研究, 神经网络的研究陷入了低谷, 低谷期长达十多年.
- 20世纪80年代, 随着计算机性能的提升和反向传播算法(back propagation, BP)受到重视, 研究者们再次打开了被Minsky关闭的研究大门.
- 1974年, Paul Werbos在哈佛大学攻读博士学位期间, 就在其博士论文中发明了影响深远的著名的反向传播算法, 但在当时并未引起重视.
- 1986年, David Rumelhart, Geoffery Hinton, and Ronald Williams发表文章《Learning Representations by Back-propagating Errors》, 重新报道这一方法, BP神经网络学习算法才受到重视, 为多层神经网络的学习提供了切实可行的解决途径.



7.2.1 神经网络的发展史

- 多层神经网络的结构如下图所示, 由一个输入层(input layer), 若干隐藏层(hidden layer), 一个输出层(output layer)组成:




- 信息从输入层流向输出层, 中间可能经过多个隐藏层, 因此也称为前馈神经网络(feedforward neural network, FFNN).
- 图中展示的是前馈神经网络的一种特定类型, 网络中的每个神经元都与前一层的每个神经元相连接, 因此也称为全连接神经网络(fully connected neural network)或多层感知机(multilayer perceptron).



7.2.1 神经网络的发展史

- 1989年, Kurt Hornik等人发表论文《Multilayer Feedforward Networks are Universal Approximations》, 从理论上证明了仅有单个隐藏层的神经网络在隐藏层足够宽的情况下能以任意精度近似任意连续函数.
- 这个定理被称为通用近似定理或万能近似定理(the universal approximation theorem).
- 除理论上的进展外, 多层神经网络在许多实际应用上也说明了其效用与价值, 如语音识别、手写识别等.
- 例如1989年, 在AT&T贝尔实验室的Yann LeCun等人展示了反向传播在现实世界中的一个重要应用: 手写邮政编码识别.
- 但在1980年代末, 人们已经知道, 用反向传播训练的深层网络并不十分有效, 本质原因是反向传播依赖于在输出层计算误差后基于微分的链式法则将误差传导至前面的隐藏层, 而多次的微分操作会产生非常大或非常小的数值, 导致训练效果不佳.
- 这就是“梯度消失或梯度爆炸”问题.
- 而在20世纪90年代中期, 支持向量机诞生, 在许多方面体现出对比神经网络的优势, 神经网络的研究再次陷入低谷.



7.2.1 神经网络的发展史

- 但仍然有一小部分研究人员在这种研究环境中坚持不懈,并最终使神经网络成为今天的样子.

“Ask anyone in machine learning what kept neural network research alive and they will probably mention one or all of these three names: **Geoffrey Hinton**, fellow Canadian **Yoshua Bengio** and **Yann LeCun**, of Facebook and New York University.” ...



引用段落出处: <http://www.thestar.com/news/world/2015/04/17/how-a-toronto-professors-research-revolutionized-artificial-intelligence.html>



7.2.1 神经网络的发展史

- 最后我们将到达故事的结尾,看看深度学习是如何从此次神经网络的低迷中崛起的.
- LeCun和Hinton多次提到,在那个时期,他们或他们学生的论文常常因为涉及神经网络而被拒绝发表.
- 但他们仍然在资助资金有限的情况下努力继续在神经网络上的工作.
- 据Hinton所说,他们策划了一个“阴谋”,将不被看好的神经网络领域重新命名为深度学习(deep learning).
- 然后,每个研究者都梦寐以求的事情真的发生了,Hinton等人于2006年发表突破性论文《A Fast Learning Algorithm for Deep Belief Nets》,重新点燃了大家对神经网络的兴趣.
- 该论文的重要贡献之一是提出了一种有效的深度神经网络训练算法,通过巧妙地初始化权重,并结合逐层的无监督预训练和有监督微调,深度信念网络(DBN)可以在训练中快速收敛,取得优异的性能.
- 尽管该论文中使用的方法目前已被新的工作所取代,但可以说,深度学习的运动是从这篇论文开始的,它是一个分水岭,拉开了深度学习的大幕.Hinton也被称为“深度学习之父”.
- 算法的进步确实取得了成果,但是训练神经网络不仅需要优化算法,还需要另一个关键成分:数据(data).



7.2.1 神经网络的发展史

- 在很长一段时间, 手写数字的MNIST数据库是测试算法的基准数据.
- 但仅凭一组手写数字的数据集能做的事情是有限的. 对深度学习这一主题来说, 无疑最重要的发展焦点是ImageNet.




- 正如文章《The data that transformed AI research – and possibly the world》中详细报道的那样, 李飞飞教授的创建一个包含WordNet数据库中大多数概念的图像数据集的想法, 要创建一个前所未有的大型数据集.
- 幸运的是, 这个想法提出不久, 出现了众包(crowdsourcing)的模式, 项目得以继续进行.
- 尽管如此, 在李飞飞及其学生、合作者在2009年发布ImageNet数据集和相关论文前, 还是花了几年的时间.
- 到2009年, ImageNet数据集已包含约320万张图像, 覆盖5247个概念.

文章链接: <https://qz.com/1034972/the-data-that-changed-the-direction-of-ai-research-and-possibly-the-world>
ImageNet官网: <https://www.image-net.org/>



7.2.1 神经网络的发展史



- 尽管如此, 计算机视觉社区并没有立即意识到这个数据集能够促进重大进展.
- 虽然ImageNet Large Scale Visual Recognition Challenge (ILSVRC)将数据集大幅简化(仅包含1000种对象类型和15万张图像), 第一年的获胜作品在测试数据集上的表现仍然不尽人意.
- 这是一个困难的问题, 也因此是一个很好的用于展示神经网络潜力的挑战. 但还需要几年时间和深度学习谜题的最后一块拼图, 才能达到这一点.




7.2.1 神经网络的发展史

- 最后这块拼图是: 算力(computational power).
- 遵循摩尔定律, 自90年代缓慢的时代以来, 计算机的速度提高了数十倍, 使得使用大型数据集和许多层次的学习变得更加可行. 但即便如此, 这还不够—CPU在速度增长方面开始触及瓶颈, 计算能力主要通过多个CPU进行弱并行计算而增加.
- 要学习深度模型中的数百万个权重参数, 就必须摆脱CPU弱并行性的限制, 转而采用GPU的大规模并行计算能力.

Deep Learning =


Lots of training data + Parallel Computation + Scalable, smart algorithms

The Deep Learning “Computer Vision Recipe”



7.2.1 神经网络的发展史

■ 神经网络研究的三起两落:



第七章 常用监督学习模型与方法II

- 7.1 树木与森林
- 7.2 神经网络模型
 - 7.2.1 神经网络的发展史
 - 7.2.2 卷积神经网络
 - 7.2.3 循环神经网络
 - 7.2.4 注意力机制与Transformer



引言

- 对于不同神经网络模型的理解层次:
 - 大体了解模型的基本理念、架构、常见应用. 
 - 能够写出代码实现模型的训练与应用.

**Talk is cheap.
Show me the code.**

- 深刻理解模型设计的数学原理.




7.2.2 卷积神经网络

- 卷积神经网络(convolutional neural networks, CNN)是一类包含卷积计算且具有深度结构的前馈神经网络, 是一类强大的、为处理图像数据而设计的神经网络.
- 基于CNN架构的模型在计算机视觉 (computer vision)领域中占主导地位, 当今大部分的图像识别、目标检测等相关学术竞赛和商业应用都以这种模型为基础.
 - 在CNN出现之前, 图像处理是人工智能的一个难题, 传统图像处理技术依赖于手工提取的特征.
 - 在CNN出现之后, 神经网络可以从原始图像中自动学习复杂和高级的特征表示, 使得图像处理变得更加自动化和精确.
- CNN的发展最早可以追溯到20世纪60年代, 神经科学家David Hubel和Torsten Wiesel对猫大脑中的视觉系统的研究.
 - 他们通过实验发现了视觉皮层中的简单细胞(simple cells)和复杂细胞(complex cells), 这些细胞对特定的视觉刺激(如光线方向和边界)有着特定反应.
 - 他们的工作揭示了视觉处理的分层结构, 描述了从简单视觉特征到更复杂的感知和认知过程的转变, 为后续神经科学与认知科学研究奠定了基础, 他们也因此获得了1981年诺贝尔生理学或医学奖.



7.2.2 卷积神经网络

- 下面我们将逐步了解CNN. 首先你需要了解一张图片在计算机眼中的样子:



- 我们看到的是图像的整体视觉效果,但计算机读取的图像是通过像素(pixel)矩阵标识的.
- 每个像素具有一个(灰度图)/三个(彩色图)数值(0-255),表示特定颜色的强度.
- 彩色图像是三个像素矩阵(RGB三原色)的叠加.




7.2.2 卷积神经网络

- 一个CNN由以下三个基础部分组成, 多个基础部分交叉堆叠而成的更深、结构更复杂的CNN.




- 卷积层中创建多个卷积核(kernel, 即特定大小的权值矩阵, 默认是 3×3 矩阵), 用于不同图像特征的提取.
- 卷积核从图像矩阵的左上角开始执行逐元素乘法, 并相加后获得一个像素值存储在新矩阵中, 即卷积后的特征矩阵.
- 卷积的过程可以简单理解为原矩阵经过滤镜后得到新矩阵.
- 卷积核中的权值是需要通过数据进行训练得到的参数.




7.2.2 卷积神经网络

■ 不同卷积核效果示例:

原图



边缘检测




$$\begin{bmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{bmatrix}$$

锐化




$$\begin{bmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{bmatrix}$$

浮雕



$$\begin{bmatrix} -2 & -1 & 0 \\ -1 & 1 & 1 \\ 0 & 1 & 2 \end{bmatrix}$$

模糊





$$\frac{1}{9} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}$$




7.2.2 卷积神经网络

- 卷积层的实现中还有一些细节, 包括卷积步长(stride)和边距扩展(padding).
 - 卷积步长表示卷积核滑动时横向及纵向移动时的单元格数量.
 - 边距扩展是在指定卷积核尺寸与卷积步长后, 希望经过卷积后的特征图具有指定大小而在输入矩阵周围补0的操作.



7.2.2 卷积神经网络

- 经过卷积层后得到的特征矩阵(也称为特征图, feature map)会再经过一个池化操作(pooling).
- 两种常见的池化方式是: 最大池化(max pooling)与平均池化(average pooling).




- 池化的主要作用是降低特征图的尺寸, 从而减少参数数量和计算复杂度, 同时也帮助提高模型的泛化能力.




7.2.2 卷积神经网络

■ CNN结构示例:



■ CNN的思想是提取特征的层次结构






■ CNN所需参数少于传统全连接神经网络, 且卷积很容易用GPU并行计算, 因此受到大家的欢迎



7.2.2 卷积神经网络

- CNN在实际中的应用非常广泛:
 - 图像检索 (image retrieval)
 - 目标检测 (object detection)
 - 图像分割 (image segmentation)




第七章 常用监督学习模型与方法II

- 7.1 树木与森林
- 7.2 神经网络模型
 - 7.2.1 神经网络的发展史
 - 7.2.2 卷积神经网络
 - 7.2.3 循环神经网络
 - 7.2.4 注意力机制与Transformer




7.2.3 循环神经网络

- 卷积神经网络可以有效地处理空间信息,而循环神经网络(recurrent neural networks, RNN)则可以更好地处理序列信息.
- 之前我们默认数据中的样本点是独立的,但现实中的许多数据并非如此.
- 因此希望能有一种神经网络架构,它能接收一个序列作为输入,并且能够预测序列的后续.
- 许多使用RNN的例子都是基于文本数据的,因此我们在此重点介绍语言模型(language model).
- RNN只有一个物理RNN单元,但是这个RNN单元可以按序列逐步进行展开(unfolding).



7.2.3 循环神经网络



- RNN在每个时刻 t 会接受两个输入, 一个是当前时刻的单词 x_t , 一个是上一时刻的隐藏状态 h_{t-1} .
- h_{t-1} 可以理解为对之前时刻的“记忆”, 通过这种方式将不同时刻的信息关联起来. 具体地,
$$h_t = f(W_{xh}x_t + W_{hh}h_{t-1} + b_h),$$
- 其中 x_t, h_t 均为向量, W_{xh}, W_{hh} 为权值矩阵, b_h 为偏置向量, f 为激活函数.
- y_t 为 t 时刻的输出, $y_t = g(W_{hy}h_t + b_y)$, 其中 W_{hy} 为权值矩阵, b_y 为偏置向量, g 为激活函数.
- 之所以说RNN只有一个物理单元RNN是因为一系列的RNN单元中 $W_{xh}, W_{hh}, W_{hy}, b_h, b_y$ 是相同的.



7.2.3 循环神经网络

- RNN的模型结构能很好地解决序列输入问题,但在实际训练中,RNN存在一个明显的缺陷.
- 那就是当阅读很长的序列时,网络内部的信息会逐渐变得越来越复杂,以至于超过网络的记忆能力,使得最终的输出信息变得混乱无用.例如下面这句话:


我觉得这家餐馆的菜品很不错,烤鸭非常正宗,包子也不错,酱牛肉很有嚼劲,但是服务员态度太恶劣了,我们在门口等了50分钟都没有能成功进去,好不容易进去了,桌子也半天没人打扫,整个环境非常吵闹,我的孩子都被吓哭了,我下次不会带朋友来。

- 即经典的RNN不能保持长期的信息之间的依赖关系.
- 为解决这个问题,研究者提出了长短时记忆网络(Long Short-Term Memory, LSTM),它是RNN的一种类型,它的设计理念可简单理解为有选择的记忆比记忆整句话更加容易且有效.
- LSTM通过引入门控(gated control)机制来控制LSTM单元需要记忆哪些信息,遗忘哪些信息,从而保持更长的信息依赖,更加轻松地表达整个句子语义.



7.2.3 循环神经网络

■ LSTM单元的内部结构:



$$c_t = f_t * c_{t-1} + i_t * g_t$$

$$h_t = o_t * \text{activation}(c_t)$$

*表示按元素乘

- 与经典RNN单元之间仅传递隐藏状态 h 不同, LSTM单元之间还传递一个额外的状态 c , 称为单元状态(cell state).
- 单元状态为LSTM增加了一个可以相距较长时间间隔来传递信息的方法, 它控制着整个LSTM的长期记忆.
- 而LSTM的关键, 就是怎样控制长期状态 c .
- LSTM的思路是使用三个门作为信息传输的控制开关.
- 遗忘门 f_t 控制前一时刻的 c_{t-1} 要遗忘哪些信息.
- 输入门 i_t 控制当前时刻的输入信息需要向 c_t 中注入哪些信息.
- 输出门 o_t 控制当前时刻的 c_t 需要对外输出(h_t)哪些信息.



7.2.3 循环神经网络

- 在上面的讲述中, RNN每一时刻的输入 $\mathbf{x}_t$ 是一个向量, 它代表一个单词. 一个自然的问题是, 单词是如何表示为向量的呢?
 - 在第六章朴素贝叶斯法的实例中, 我们演示了如何对点评网站yelp上的评论数据进行正负面分类, 其中用到了一种将单词(或词元, token)表示为向量的原始方法.
 - 这种方法称为独热编码(one-hot encoding), 每个词对应一个高维向量, 向量中除了一位为1以外其余位都是0, 词向量的维度与系统的词汇量一样大.
 - 独热编码简单直接, 但词向量维度高而稀疏, 且无法度量不同词之间的语意距离是否接近.
 - 为了解决这个问题, 许多研究者投入到对单词进行低维稠密表示(称为词嵌入, word embedding)的研究中, 其中最著名的工作是2013年Tomas Mikolov等人提出的word2vec.
 - 2013年, Tomas Mikolov等人在NeurIPS发表论文《Distributed Representations of Words and Phrases and their Compositionality》, 提出了开创性的词嵌入技术word2vec, 并获得2023年NeurIPS时间检验奖(Test of Time).

<https://blog.neurips.cc/2023/12/11/announcing-the-neurips-2023-paper-awards/>



7.2.3 循环神经网络



- 假设系统的词汇量为 N , 每个词都表示为一个 k 维向量, 则所有词向量构成一个 $N \times k$ 维矩阵.
- word2vec的训练就是对这个词嵌入矩阵进行更新的过程.
- word2vec可直接使用海量文本语料以自监督学习(self-supervised learning)的方式进行训练, 使用的训练模型有: 连续词袋模型(continuous bag-of-words, CBOW)和跳字模型(skip-gram).

CBOW - 通过上下文词预测目标词

南科大 是 _____ 研究型 大学
输入 输入 输出 输入 输入


Skip-gram - 通过目标词预测上下文词

_____ 最好的 _____
输出 输出 输入 输出 输出




7.2.3 循环神经网络


- 研究人员发现, 语义相似的词汇在词向量空间中的位置会十分接近, 而语义无关的词之间则相距较远, 并且计算有相似关系的单词之间的位移向量也会十分相似.



Male-Female



Verb tense




Country-Capital

- word2vec在实际中有广泛的应用, 不仅开启了自然语言处理领域的新时代, 是后续预训练模型的基石, 也启发了推荐系统、图嵌入等领域的相关方法与应用.
- 尽管word2vec非常成功, 但它学习到的词向量是静态的, 无法解决一词多义问题, 后续又有许多研究者投入到动态词嵌入的研究中.



7.2.3 循环神经网络


- 回到RNN模型, 需要注意, RNN的模型结构并不要求每一时刻都有输入或输出:



7.2.3 循环神经网络

- 异步的序列到序列的模式也称为**编码器-解码器(Encoder-Decoder)**结构、**sequence to sequence (Seq2seq) 模型**. 典型的应用场景是**机器翻译(machine translation)**.
 - Seq2seq由Encoder和Decoder两个RNN构成.
 - Encoder负责将输入序列消化吸收成一个向量, 通常称其为**context vector** (如Encoder RNN的最后一个隐藏状态向量), 而Decoder则根据context vector来生成文字.

Neural Machine Translation
SEQUENCE TO SEQUENCE MODEL



第七章 常用监督学习模型与方法II

- 7.1 树木与森林
- 7.2 神经网络模型
 - 7.2.1 神经网络的发展史
 - 7.2.2 卷积神经网络
 - 7.2.3 循环神经网络
 - 7.2.4 注意力机制与Transformer



7.2.4 注意力机制与Transformer

- 注意力机制(attention mechanism)很像人类看图片的情况.




- Attention的本质是从关注全部到关注重点.
- 我们的视觉系统就有attention机制, 将有限的注意力集中在重点信息上, 节省资源, 快速获得最有效的信息.
- 神经网络模型中的attention机制最早也是在计算机视觉领域应用的.
- 随后attention机制通过机器翻译任务首次引入自然语言处理领域.
- 自Transformer针对机器翻译任务被提出后, 其最核心的部分—self-attention(自注意力)机制也逐渐成为了各领域的通用架构.



7.2.4 注意力机制与Transformer

- 回到7.2.3小节最后介绍的Encoder-Decoder框架:




- 其中Encoder对源语句进行编码转化为中间语义表示向量: $c = \mathcal{F}(x_1, x_2, \dots, x_n)$.
- 然后Decoder根据中间语义表示向量逐个生成单词: $y_i = \mathcal{G}(c, y_1, \dots, y_{i-1})$.
- 不论生成哪个单词 $y_1, y_2, \dots, y_m$,都使用了同样的语义编码 c ,而 c 是由源语句的每个单词经过Encoder编码产生的,即源单词对生成某个目标单词 y_i 来说影响力是相同的.
- 因此,这样的模型可以视为**注意力不集中**的分心模型,且 c 可能无法记忆长距离信息.



7.2.4 注意力机制与Transformer

- 在机器翻译的Seq2seq模型中, attention机制作了如下调整:
 - 首先, 不仅仅使用Encoder的最后一个隐藏状态向量作为context vector, 而是会把所有隐藏状态向量都传递给Decoder使用.
 - 其次, Decoder在解码时每一步会对所有隐藏状态向量进行加权平均, 为与该时间步输出更相关的隐藏状态向量赋予更高的权重. 总结来说就是: 动态赋权, 加权平均.





- attention机制实现动态赋权的具体细节不在这里深入讲解, 简单来说就是attention中主要进行的是词向量与矩阵的乘法运算, 这些矩阵是需要学习的参数, 与Encoder-Decoder中的参数一样, 可通过大规模翻译语句对进行学习.




7.2.4 注意力机制与Transformer

- Attention机制不仅解决了基于RNN的Seq2seq模型的长距离记忆问题, 还带来了一个十分重要的性质: 可解释性(interpretability).
 - 可以对attention的权重进行可视化, 以理解机器翻译的过程.
 - 注意, 模型并不仅学习到了源语句与目标语句中单词的简单顺序对应关系, 还学习到了交换单词顺序、一对多等较复杂的关系.



7.2.4 注意力机制与Transformer



- 2017年, Google团队在NeurIPS发表论文《Attention is all you need》, 提出的Transformer架构中引入了self-attention机制, 完全消除了模型训练过程对RNN的依赖.
 - 前面介绍的attention是去捕捉源语句与目标语句的词与词之间的依赖关系.
 - 但是这忽略了源语句或目标语句内部词与词之间的依赖关系, 如下图.



7.2.4 注意力机制与Transformer

■ Transformer的整体架构如右图

- 仍然由编码器和解码器组成.
- 与基于RNN的编码器-解码器结构不同, **编码器与解码器的个数是固定的**(6个), 与源语句/目标语句序列长度无关.
- 在模型训练中, 源语句与目标语句分别作为编码端和解码端的输入, 单词并非是逐个输入的, 而是整个语句中所有单词的词嵌入向量并成一个矩阵作为输入.
- 而为了保留单词间的序列位置信息, 编码端和解码端的输入其实是每个单词的语义嵌入与**位置嵌入(position embedding)**的和.




7.2.4 注意力机制与Transformer

- 《Attention is all you need》论文中展示了Encoder和Decoder的内部详细结构。
- 6个Encoder的结构相同, 主要由一个自注意力层+一个全连接层组成。
- 6个Decoder的结构也相同, 主要由一个自注意力层+一个交叉注意力层+一个全连接层组成。
- 具体细节不做详细解释, 大体了解这个结构的理念即可。
- 经过自注意力层后, 每个输入单词仍然对应一个向量, 这个向量不仅包含单词本身的语义信息、序列位置信息, 还有上下文信息。



- Encoder和Decoder各自的自注意力层分别负责捕捉源语句和目标语句自身的词语依赖关系. 而Decoder的交叉注意力层负责捕捉源语句和目标语句之间的词语依赖关系。




7.2.4 注意力机制与Transformer

- Transformer引入的自注意力机制,使得模型可以对输入序列的单词进行全面关注,对长距离依赖关系的处理非常有效.
- 与RNN不同,Transformer的训练不依赖于对输入序列的逐步计算,更容易进行并行处理.
- 后续许多自然语言处理模型,尤其是大语言模型(LLM, large language model),都基于Transformer架构,通过在大规模数据上进行预训练,大大提高了模型在各种自然语言任务上的表现.
- 由于Transformer高度的并行化特性和灵活的架构,它也被广泛应用于自然语言处理之外的其他领域,如图像处理、语音识别、蛋白质结构预测等.这使得它成为一个通用的基础模型,启发了各种领域中基于Transformer的模型设计.
- 下面我们简单看看大语言模型的进化过程.

AlphaFold 3一夜预测地球所有生物分子, 谷歌DeepMind颠覆生物学登Nature头版!

原创 新智元 新智元 2024-05-09 11:05 北京

听全文




【新智元导读】谷歌DeepMind^Q又有重磅研究了! AlphaFold 3一经推出, 就登上Nature头版。从此, 人类冲破「蛋白质宇宙」, 所有生物分子结构都可以预测了! 这次使用的, 还是AI革命最核心的组合架构——Transformer+Diffusion。

时隔3年, AlphaFold 3横空出世, 再次掀起AI学术圈巨震!



7.2.4 注意力机制与Transformer



- 解码器模型逐渐成为LLM发展的主导, 而编码器模型逐渐消失.
- 编码器-解码器模型仍然在被积极探索中, 仍有一定发展前景, 且Google已开源了许多相关模型.
- 2020年之前, 大多数模型是开源的, 而随着GPT-3的推出, 越来越多的公司选择闭源模式.



7.2.4 注意力机制与Transformer

- 不同解码器模型在模型架构上是类似的,一些细节(如位置嵌入、归一化、激活函数等)有细微差异,而主要的区别在于参数数量与训练数据.

Model	Key Innovations	Training Set	Parameters Count	Context Window
GPT-1 2018	• Pre-trained Transformer decoder • Self-supervised training + fine-tuning	4.5 GB	117 M	512
GPT-1 2019	• Modified normalization layers • First results on Zero-Shot Learning	40 GB	1.5 B	1,024
GPT-3 2020	• Sparse Attention layers • First results on Few-Shot Learning	57 TB	175 B	2,048 tokens
GPT-4 2023	• Multimodal input (text + images) • Top 10% score on Medicine/Law exams.	?	1.76 T	32,000 tokens



Conventional model-centric approach:

$$AI = \text{Code} + \text{Data}$$

(algorithm/model)
Work on this

Data-centric approach:

$$AI = \text{Code} + \text{Data}$$

(algorithm/model)
Work on this

- 数据非常重要,大模型的研究热点开始从model engineering转移到data engineering,主要研究如何高效地构建高质量和大数量的数据集.



